

Лабораторна робота №1

З дисципліни «Вступ до технології Data Science»

Тема: «Підготовка та аналіз даних для статистичного навчання»

1. Постановка задачі

Мета роботи

Виявити, дослідити та узагальнити особливості застосування методів статистичного навчання для задач визначення статистичних характеристик вхідного потоку даних з використанням спеціалізованих пакетів мови програмування Python.

Завдання

1. Провести парсинг самостійно обраного сайту.
 2. Зберегти результати парсингу у файл.
 3. Оцінити динаміку тренду реальних даних.
 4. Визначити статистичні характеристики отриманих даних.
 5. Синтезувати та верифікувати модель даних, аналогічних реальним за трендом та статистичними характеристиками.
 6. Провести аналіз отриманих результатів.
-

2. Виконання

2.1. Парсинг вебсайту

Для збору даних було обрано сайт <https://www.minusrus.com/>, який містить інформацію про втрати російського війська з початку повномасштабного вторгнення.

Для аналізу були обрані такі категорії:

- особовий склад;
- бойові броньовані машини;
- танки;

- артилерія;
- літаки;
- гелікоптери;
- кораблі.

Для реалізації парсингу використано бібліотеки:

- requests;
- BeautifulSoup;
- pandas.

Алгоритм роботи програми:

- надсилання HTTP GET-запиту;
- перевірка статусу відповіді;
- отримання HTML-коду сторінки;
- пошук необхідних HTML-елементів;
- очищення числових значень;
- запис отриманих даних у словник;
- виведення результатів парсингу.

Після виконання програми було отримано HTML-код сторінки та сформовано набір даних для подальшої роботи.

2.2. Збереження результатів парсингу

Результати парсингу зберігаються у файл формату **.xlsx**.

Програма перевіряє, чи існує файл із попередніми результатами.

Якщо файл існує:

- зчитуються попередні записи;
- нові дані додаються до вже існуючих.

Якщо файл відсутній:

- створюється новий DataFrame;
- результати записуються у новий Excel-файл.

Таким способом формується датасет, який накопичується протягом кількох днів парсингу.

Для лабораторної роботи було зібрано дані за період **1–21 вересня 2023 року**.

2.3. Оцінка динаміки тренду

На цьому етапі виконується:

- зчитування даних із Excel;
- сортування за датою;
- вибір необхідної категорії даних;
- побудова тренду.

Користувач може обрати одну із категорій:

- особовий склад;
- бойові броньовані машини;
- танки;
- артилерія;
- літаки;
- гелікоптери;
- кораблі.

Для визначення тренду застосовано **метод найменших квадратів (МНК)**.

Отримано регресійну модель:

$$y(t) = 263418.70129870024 + 602.9829118250829 \cdot t - 2.5153793574886176 \cdot t^2$$
$$y(t) = 263418.70129870024 + 602.9829118250829 \cdot t - 2.5153793574886176 \cdot t^2$$

Аналіз показав, що досліджувані дані мають практично лінійний характер зміни.

2.4. Визначення статистичних характеристик

Після побудови тренду визначаються статистичні характеристики вибірки.

Для цього:

- віднімається тренд від реальних даних;
- обчислюється математичне сподівання;
- визначається дисперсія;
- обчислюється середньоквадратичне відхилення.

У результаті програма виводить:

- кількість елементів вибірки;
- математичне сподівання;
- дисперсію;
- середньоквадратичне відхилення.

2.5. Синтез та верифікація моделі

На основі отриманої регресійної моделі синтезовано штучну часову послідовність.

Спочатку формується модель, що повторює тренд реальних даних.

Далі до неї додається випадковий шум, який генерується за нормальним законом розподілу.

Після цього для синтезованої моделі визначаються:

- математичне сподівання;
- дисперсія;
- середньоквадратичне відхилення;
- динамічна похибка моделі.

Для оцінювання якості моделі використовується коефіцієнт детермінації R^2 .

Отримане значення:

$R^2 = 0.9900093635200369$

що свідчить приблизно про **99 % відповідності моделі реальним даним**.

2.6. Аналіз отриманих результатів

Під час аналізу було встановлено:

- вхідна вибірка складається з реальних даних;
 - дані мають часову надмірність та майже лінійний характер;
 - обсяг вибірки становить 21 спостереження;
 - середнє значення розподілу близьке до нуля;
 - середньоквадратичне відхилення становить **65.85632563450527**;
 - отримано квадратичну регресійну модель;
 - синтезована модель повторює тренд реальних даних;
 - статистичні характеристики синтезованої моделі близькі до характеристик реальної вибірки;
 - середньоквадратичне відхилення моделі становить **54.699295080578075**;
 - динамічна похибка моделі дорівнює **40.082313314344816**;
 - коефіцієнт детермінації дорівнює **0.9900093635200369**, що підтверджує високу якість моделі.
-

Висновок

У ході виконання лабораторної роботи було досліджено застосування методів статистичного навчання для аналізу реальних даних засобами Python.

Було реалізовано парсер вебсайту, сформовано датасет, визначено статистичні характеристики вибірки, побудовано регресійну модель та синтезовано штучну модель, яка відтворює тренд і статистичні властивості реальних даних.

Для перевірки адекватності моделі було використано коефіцієнт детермінації R^2 , який показав близько 99 % відповідності реальним даним.

Результати підтверджують правильність виконання поставленого завдання та демонструють можливість використання розроблених програм для парсингу вебресурсів, статистичного аналізу даних і побудови моделей, аналогічних реальним даним за їхніми статистичними характеристиками.