

Лабораторна робота №2

З дисципліни «Вступ до технології Data Science»

Тема: «Статистичне навчання з поліноміальною регресією»

1. Постановка задачі

Мета роботи

Дослідити та узагальнити особливості реалізації процесів статистичного навчання із застосуванням методів обробки великих масивів даних (Big Data) та Калманівської рекурентної фільтрації засобами мови програмування Python.

Завдання

1. Отримати вхідні дані з характеристиками, сформованими у лабораторній роботі №1.
 2. Побудувати модель вхідних даних з аномальними вимірами.
 3. Очистити вхідні дані від аномальних вимірів, самостійно обравши метод виявлення та очищення аномалій.
 4. Визначити показники якості моделі та виконати її оптимізацію.
 5. Реалізувати рекурентне згладжування за допомогою α - β або α - β - γ фільтра та забезпечити стійкість його роботи.
 6. Провести аналіз отриманих результатів і верифікацію розробленої програми.
 7. Реалізувати R&D-процеси для етапів статистичного навчання.
-

2. Виконання

2.1. Отримання вхідних даних

Для виконання роботи використано дані, отримані у лабораторній роботі №1. Вони містять інформацію про втрати російського війська за період **1–21 вересня 2023 року**.

Дані зберігаються у форматі **.xlsx** та представлені такими категоріями:

- особовий склад;
- бойові броньовані машини;
- танки;
- артилерія;
- літаки;
- гелікоптери;
- кораблі.

Для роботи дані перетворюються у структуру **DataFrame** та сортуються за датою у зростаючому порядку.

Користувач може обрати один із двох режимів роботи:

- використання синтезованої моделі;
- використання реальних даних.

Також передбачено вибір категорії даних для подальшого аналізу. У роботі як приклад використано категорію **«Кораблі»**.

Після отримання вибірки визначаються:

- поліноміальна регресійна модель методом найменших квадратів;
- статистичні характеристики вибірки:
 - математичне сподівання;
 - дисперсія;
 - середньоквадратичне відхилення.

Отримані коефіцієнти регресії використовуються для подальшого моделювання даних.

2.2. Побудова моделі з аномальними вимірами

На основі коефіцієнтів поліноміальної регресії будується модель, яка відтворює тренд реальних даних.

Для наближення моделі до реальних вимірювань до неї додається випадковий шум, що генерується за нормальним законом розподілу.

Після цього визначаються статистичні характеристики моделі:

- математичне сподівання;
- дисперсія;
- середньоквадратичне відхилення;
- динамічна похибка моделі.

Порівняння показало, що характеристики моделі максимально наближені до характеристик реальної вибірки, що підтверджує правильність її побудови.

Далі до моделі додаються аномальні значення.

Аномалії моделюються шляхом генерації випадкових відхилень за нормальним законом розподілу.

У результаті формується модель, що містить:

- тренд;
- нормальний шум;
- аномальні викиди.

Зростання середньоквадратичного відхилення підтверджує успішне внесення аномалій до вибірки. Аналогічний функціонал реалізовано і для реальних даних.

2.3. Очищення даних від аномалій

Для очищення даних реалізовано три різні алгоритми:

- метод медіан;
- метод найменших квадратів (МНК);
- метод ковзного вікна.

Користувач має можливість самостійно обрати алгоритм очищення.

Метод медіан

Алгоритм працює за принципом ковзного вікна.

Для кожного вікна визначається медіана. Якщо поточне значення відхиляється від медіани більше за встановлений поріг, воно вважається аномальним і замінюється медіаною.

Експериментально встановлено такі залежності параметрів алгоритму:

- розмір вікна:

`window_size = len(вибірки) / 4`

- поріг:

`threshold = 2 × середньоквадратичне відхилення`

Для оцінювання якості очищення використовуються дві метрики:

- MAE (Mean Absolute Error);
- коефіцієнт детермінації R^2 .

Результати показали:

- СКВ до аномалій — **0.257**;
- після внесення аномалій — **0.337**;
- після очищення — **0.290**.

Також отримано:

- **MAE = 0.292**;
- **R² = 0.766**.

Це підтверджує працездатність алгоритму.

Метод МНК

Метод використовує поліноміальну регресію для побудови моделі та визначення відхилень між реальними значеннями й прогнозом.

Аномаліями вважаються точки, які відхиляються від тренду більше за встановлений поріг.

Експериментально отримано:

- розмір вікна:

window_size = len(вибірки) / 4

- поріг:

threshold = 50 × середньоквадратичне відхилення

Після очищення отримано:

- СКВ до аномалій — **0.234**;
- після аномалій — **0.354**;
- після очищення — **0.230**.

Якість очищення:

- **MAE = 0.233**;
- **R² = 0.839**.

Алгоритм успішно виявляє та усуває аномальні значення.

Метод ковзного вікна

Метод використовує локальні характеристики вибірки.

Для кожного ковзного вікна визначається медіана, яка використовується для згладжування даних.

Експериментально визначено:

window_size = len(вибірки) / 5

Після очищення отримано:

- СКВ до аномалій — **0.210**;
- після аномалій — **0.310**;
- після очищення — **0.175**.

Якість алгоритму:

- **MAE = 0.199**;
- **R² = 0.875**.

За отриманими результатами цей алгоритм показав найкращу ефективність серед трьох реалізованих методів.

2.4. Оптимізація моделі

Для оцінювання якості використовуються дві метрики:

- MAE;
- коефіцієнт детермінації R².

Оптимізація полягає у мінімізації функції:

MAE + (1 - R²)

Під час оптимізації автоматично підбираються:

- розмір вікна;
- порогове значення.

Після оптимізації моделі методом медіан отримано:

- MAE зменшилась з **0.292** до **0.195**;
- R² збільшився з **0.766** до **0.901**.

Це свідчить про успішне покращення якості моделі. Аналогічно було оптимізовано метод МНК та метод ковзного вікна.

2.5. Рекурентне згладжування alfa-beta фільтром

Оскільки досліджувані дані мають лінійну залежність, для їх згладжування використано **alfa-beta фільтр**.

Фільтр виконує рекурентне оцінювання значень часового ряду та їх швидкості зміни.

Після застосування фільтра було оцінено якість результатів за допомогою MAE та коефіцієнта детермінації.

Отримані результати показали, що на початку роботи фільтр проходить стадію навчання, після чого переходить у режим стабільної роботи та успішно відстежує зміни вхідних даних.

2.6. Аналіз отриманих результатів

Під час виконання лабораторної роботи було встановлено:

- використано реальні дані, отримані у лабораторній роботі №1;
 - реалізовано можливість роботи як із реальною вибіркою, так і з її моделлю;
 - успішно змодельовано аномальні вимірювання, що підтверджується збільшенням середньоквадратичного відхилення;
 - реалізовано три алгоритми очищення даних від аномалій;
 - усі алгоритми зменшують середньоквадратичне відхилення після очищення;
 - найкращі результати продемонстрував метод ковзного вікна;
 - визначено показники якості MAE та R^2 ;
 - реалізовано автоматичну оптимізацію параметрів алгоритмів очищення;
 - після оптимізації MAE зменшилася з **0.292** до **0.195**, а R^2 збільшився з **0.766** до **0.901**;
 - реалізовано alfa-beta фільтр для рекурентного згладжування;
 - встановлено залежність між статистичними характеристиками вибірки та параметрами алгоритмів очищення аномалій.
-

Висновок

У ході виконання лабораторної роботи було досліджено особливості статистичного навчання із застосуванням методів обробки великих масивів даних та Калманівської рекурентної фільтрації.

На основі статистичних характеристик вибірки реалізовано алгоритми виявлення та усунення аномалій, зокрема метод медіан, метод найменших квадратів і метод ковзного

вікна. Проведено їх оптимізацію та оцінено якість за допомогою показників MAE і коефіцієнта детермінації R^2 .

Також реалізовано рекурентне згладжування за допомогою alfa-beta фільтра, який продемонстрував ефективне відстеження зміни даних після завершення етапу навчання.

Результати підтвердили, що статистичні характеристики вибірки є важливими для побудови ефективних алгоритмів очищення даних та їх оптимізації. Розроблена програма може бути використана для завантаження, обробки, аналізу великих масивів даних і виявлення закономірностей, що можуть бути корисними під час прийняття рішень.